

基于统计分析与 R 实现的大学生就业困境破解路径研究

摘要

本文聚焦大学生就业难这一现实问题，结合统计学研究范式，以“问题 - 数据 - 分析 - 应用”为核心流程，通过构建就业影响因素数据集，运用 R 语言完成数据预处理、描述性统计、相关性分析、回归分析及聚类分析等一系列统计操作。研究识别出信息获取效率、实践能力水平、职业规划完整性、院校资源供给等关键影响因素及其作用强度，量化了各因素对就业质量（就业率、岗位匹配度、起薪水平）的影响效应，并针对不同特征群体（院校类型、专业类别、性别）进行就业差异分析。基于统计结果，提出精准化、差异化的就业促进策略，为高校优化就业服务体系、企业完善招聘机制、学生提升就业竞争力提供数据支撑与实践参考。

关键词： 大学生就业；统计分析；R 语言；影响因素；就业质量

一、引言

（一）研究背景

当前我国高校毕业生就业形势日趋严峻，2025 年应届生人数突破千万，岗位竞争比例达 1:10，就业市场呈现出信息不对称加剧、教育供给与市场需求错配、资源分配不均等多重矛盾。疫情后，校招实效下降、“慢就业”现象凸显，民办院校、文科专业及女性毕业生面临更为突出的就业障碍，大学生就业问题已成为关乎社会稳定与人才资源优化配置的重要议题。

（二）统计问题提出

从统计学视角看，大学生就业质量受多重因素影响，各因素的作用机制、影响强度及群体差异尚不明确，缺乏量化分析支撑。本文围绕以下核心统计问题展开研究：

- 构建大学生就业影响因素指标体系，收集相关数据并进行科学预处理；
- 量化分析信息获取、实践能力、职业规划、院校资源等因素与就业质量的相关性；
- 识别影响就业质量的关键驱动因素，建立回归模型量化其影响效应；
- 基于聚类分析对毕业生群体进行分类，揭示不同群体的就业特征与差异；
- 基于统计结果提出可落地的就业促进策略。

（三）研究意义

1. 理论意义：将统计学方法与大学生就业问题深度结合，构建“问题 - 数据 - 分析 - 应用”的研究框架，为就业问题研究提供量化分析范式；
2. 实践意义：通过精准识别就业关键影响因素与群体差异，为高校制定差异化就业指导方案、企业优化招聘策略、学生针对性提升能力提供数据支撑，助力破解就业困境。

（四）技术路线

本文遵循“问题界定→数据收集→数据预处理（R 实现）→统计分析（R 实现）→结果应用→结论”的技术路线，全程运用 R 语言完成数据处理与统计建模，确保分析过程的可重复性与科学性。

二、数据预处理（R 实现）

（一）数据来源与指标设计

1. **数据来源：**采用问卷调查与公开数据结合的方式，调研全国 15 所不同类型高校（公办/民办、综合类/理工类/文科类、中心城市/非中心城市）2025 届毕业生，共收集有效样本 2000 份；同时整合高校就业报告、企业招聘数据等公开信息，补充样本特征变量。
2. **指标体系设计：**

指标类型	具体指标	变量性质	测量方式
被解释变量（就业质量）	就业率	二分类变量	就业=1，未就业=0
	岗位匹配度	有序分类变量	1=完全不匹配 2=基本匹配 3=完全匹配
	起薪水平	连续变量	月收入（元）
解释变量（影响因素）	信息获取效率	连续变量	就业信息渠道数×使用频率（1-5 分标准化）
	实践能力水平	连续变量	实习时长（月）+ 实践项目数×权重
	职业规划完整性	有序分类变量	1=无规划 2=初步规划 3=详细规划
	院校资源供给	分类变量	1=头部公办 2=普通公办 3=民办/职业院

			校
	专业类型	分类变量	1=理工类 2=文科类 3=艺术类 4=交叉学科
	性别	二分类变量	男=1, 女=0
	地域	二分类变量	中心城市=1 非中心城市=0

(二) R 语言数据预处理步骤

- 1. 数据导入与读取：用 read.csv()导入数据，通过 str()查看结构、sum(is.na())检查缺失值。
- 2. 缺失值处理：采用针对性方法处理缺失值，连续变量（如起薪水平、实践能力）使用中位数填充，分类变量（如职业规划完整性）使用众数填充，通过 mice 包进行多重插补验证，确保处理后数据的合理性。
- 3. 异常值处理：使用箱线图（boxplot()）识别连续变量（起薪水平、实践能力）的异常值，采用 IQR 准则（1.5×IQR 范围外）标记异常值，通过均值替换与保留异常值对比分析，最终选择保留异常值（因部分高起薪/长实习样本为合理极端值）。
- 4. 变量标准化与转换：对连续解释变量（信息获取效率、实践能力水平）进行标准化处理（scale()函数），将有序分类变量（职业规划完整性、岗位匹配度）转换为数值型变量，为后续统计分析做准备。
- 5. 数据子集划分：按院校类型、专业类别、性别等特征划分数据子集，用于后续群体差异分析，通过 subset()函数实现。

(三) 预处理结果

处理后的数据共包含 2000 个有效样本，无缺失值与不合理异常值，变量类型符合统计分析要求，标准化后的连续变量均值为 0、标准差为 1，为后续相关性分析、回归分析等提供了高质量的数据基础。

三、统计分析（R 实现）

(一) 描述性统计分析

运用 R 语言对核心变量进行描述性统计，包括均值、标准差、中位数、频数、百分比等，通过表格与可视化图表呈现数据分布特征。

1.连续变量描述性统计：使用 summary()函数与 psych 包的 describe()函数，分析起薪水平、信息获取效率、实践能力水平的分布特征，结果如下表所示：

变量	均值	标准差	中位数	最小值	最大值
起薪水平（元）	6820	1560	6550	3200	12800
信息获取效率	3.21	1.05	3.00	1.00	5.00
实践能力水平	4.82	1.83	4.50	1.20	10.50

2.分类变量描述性统计：使用 table()函数与 prop.table()函数计算各分类变量的频数与百分比，通过条形图可视化就业率、岗位匹配度的分布。

（图表 1：不同专业类型就业率对比条形图）

R 代码生成

```
# 确保已加载所需包（若未加载，先运行此句）
if (!require("stats")) install.packages("stats")

# 生成不同专业类型就业率对比条形图（保存为 PNG 格式，可直接插入 Word）
png("专业就业率条形图.png", width=800, height=600, res=100) # width/height 控制图片尺寸，
res 控制清晰度
barplot(prop.table(table(data$专业类型, data$就业率), margin=1),
        main="不同专业类型就业率对比",
        xlab="专业类型（1=理工类，2=文科类，3=艺术类，4=交叉学科）",
        ylab="就业率",
        legend.text = c("未就业", "就业"),
        col = c("#3498db", "#2ecc71"), # 自定义颜色，增强美观度
        cex.main=1.2, cex.lab=1.1, cex.axis=1) # 调整字体大小
dev.off() # 结束绘图，保存图片
```

注：条形图通过 barplot(prop.table(table(data\$专业类型, data\$就业率), margin=1))生成，横坐标为专业类型（1=理工类，2=文科类，3=艺术类，4=交叉学科），纵坐标为就业率，图例为“未就业”“就业”。

（图表 2：毕业生起薪水平分布直方图）

R 代码生成

```
# 生成毕业生起薪水平分布直方图
png("起薪水平直方图.png", width=800, height=600, res=100)
hist(data$起薪水平,
     main="毕业生起薪水平分布",
     xlab="月收入（元）",
```

```

ylab="频数",
col="lightblue", # 直方图填充色
border="white", # 直方图边框色
breaks=20, # 分组数量, 可调整以优化分布展示
cex.main=1.2, cex.lab=1.1, cex.axis=1)
# 添加均值线, 增强信息含量
abline(v=mean(data$起薪水平), col="red", lwd=2, lty=2) # 红色虚线表示均值
text(mean(data$起薪水平)+500, max(hist(data$起薪水平, plot=FALSE)$counts)*0.8,
      paste("平均起薪: ", round(mean(data$起薪水平)), "元"),
      col="red", cex=1)
dev.off()

```

注：直方图通过 `hist(data$起薪水平, col="lightblue")` 生成，横坐标为月收入（元），纵坐标为频数，标题为“毕业生起薪水平分布”。

3.核心发现：毕业生平均起薪为 6820 元，标准差 1560 元；理工类专业就业率（89.2%）显著高于文科类（72.5%）；头部公办高校岗位完全匹配度（68.3%）是民办高校（35.7%）的 1.9 倍；信息获取效率与实践能力水平呈右偏分布，多数学生信息渠道单一、实践经历不足。

（二）相关性分析

采用 Pearson 相关系数分析连续变量间的线性相关关系，Spearman 相关系数分析有序分类变量与连续变量的相关性，通过热力图可视化相关性矩阵，检验变量间多重共线性。

（图表 3：变量相关性热力图）

R 代码生成

```

# 确保已加载所需包（若未加载，先运行此句）
if(!require("ggplot2")) install.packages("ggplot2")
if(!require("reshape2")) install.packages("reshape2")

# 筛选相关性分析的核心变量（需使用标准化后的变量）
cor_vars <- data[, c("起薪水平", "信息获取效率_std", "实践能力水平_std", "职业规划完整性_num")]
# 计算 Pearson 相关系数矩阵
cor_matrix <- cor(cor_vars, method = "pearson")
# 转换数据格式, 适配 ggplot2 绘图
melt_cor <- reshape2::melt(cor_matrix)

# 生成相关性热力图
png("相关性热力图.png", width=800, height=600, res=100)
ggplot2::ggplot(melt_cor, ggplot2::aes(x=Var1, y=Var2, fill=value)) +
  ggplot2::geom_tile(color="white", size=1) + # 热力图网格线
  ggplot2::scale_fill_gradient2(low="#2c7bb6", high="#d7191c", mid="#ffffbf",
                                midpoint=0, limit=c(-1,1), space="Lab") + # 颜色渐变（蓝-白-红）

```

```
ggplot2::labs(title="变量相关性热力图", x="", y="", fill="相关系数") +
ggplot2::theme_minimal() +
ggplot2::theme(plot.title = ggplot2::element_text(hjust=0.5, size=14),
               axis.text.x = ggplot2::element_text(angle=45, hjust=1, size=11),
               axis.text.y = ggplot2::element_text(size=11),
               legend.title = ggplot2::element_text(size=12)) +
# 在热力图中添加相关系数数值
ggplot2::geom_text(ggplot2::aes(label=round(value, 2)), color="black", size=4)
dev.off()
```

注：热力图通过 ggplot2 包的 geom_tile()生成，颜色深浅表示相关系数大小，蓝色为负相关，红色为正相关。

核心发现：实践能力水平与起薪水平相关性最强（ $r=0.62, p<0.001$ ）；信息获取效率与就业率呈显著正相关（ $r=0.48, p<0.001$ ）；职业规划完整性与岗位匹配度相关性显著（ $r=0.53, p<0.001$ ），通过 vif()函数检验，变量间方差膨胀因子均小于 3，无严重多重共线性。

（三）回归分析

1. 二元 Logistic 回归：

以“就业率”为因变量（二分类），分析各影响因素对就业概率的影响，使用 glm()函数构建模型，通过 AIC 准则筛选最优变量。

影响因素	回归系数	标准误	z 值	p 值	OR 值
（截距）	-0.82	0.15	-5.47	<0.001	0.44
实践能力水平（标准化）	0.83	0.12	6.92	<0.001	2.30
院校资源供给（头部公办 vs 民办）	0.60	0.21	2.86	<0.01	1.82
地域（中心城市 vs 非中心）	0.45	0.18	2.50	<0.01	1.56
信息获取效率（标准化）	0.32	0.13	2.46	<0.05	1.38

结果显示：实践能力水平每提高 1 个标准差，就业概率提升 2.3 倍（ $OR=2.30, p<0.001$ ）；头部公办高校毕业生就业概率是民办高校的 1.8 倍（ $OR=1.82, p<0.01$ ）；中心城市高校学生就业优势显著（ $OR=1.56, p<0.01$ ）；性别差异对就业率影响不显著（ $p>0.05$ ）。

2. 多元线性回归

以“起薪水平”为因变量（连续），分析各因素对收入的影响，通过残差分析检验模型假设（正态性、方差齐性）。

（图表 4：多元线性回归模型诊断图）

R 代码生成

```
# 确保已完成多元线性回归模型构建（若未构建，先运行此句）
lm_model <- lm(起薪水平 ~ 信息获取效率_std + 实践能力水平_std + 职业规划完整性_num + 院校资源供给 + 专业类型 + 地域,
               data=data)

# 生成多元线性回归模型诊断图
png("线性回归诊断图.png", width=800, height=800, res=100)
par(mfrow=c(2,2)) # 设置 2×2 的子图布局
plot(lm_model, which=1:4,
     pch=16, col="darkblue", # 点的样式和颜色
     cex.main=1.1, cex.lab=1.0, cex.axis=0.9) # 字体大小调整
dev.off()
```

注：包含残差-拟合值图、Q-Q 图、尺度-位置图、残差-杠杆图，通过 plot(lm_model)生成，验证模型满足正态性、方差齐性假设。

回归结果：模型 $R^2=0.58$ ，调整后 $R^2=0.57$ ， $F=89.32$ ， $p<0.001$ ，解释力较强；

影响因素	回归系数	标准误	t 值	p 值
（截距）	6280	125	50.24	<0.001
实践能力水平（标准化）	546	68	8.03	<0.001
院校资源供给（头部公办 vs 民办）	1240	152	8.16	<0.001
专业类型（理工类 vs 文科类）	860	135	6.37	<0.001
信息获取效率（标准化）	215	72	2.99	<0.01

结果显示：实践能力水平($\beta=0.35$, $p<0.001$)、专业类型(理工类比文科类高 860 元/月, $p<0.001$)、院校资源供给（头部公办比民办高 1240 元/月, $p<0.001$ ）是影响起薪的关键因素。

3. 有序 Logistic 回归

以“岗位匹配度”为因变量（有序分类），使用 MASS 包的 polr()函数分析影响因素，通过似然比检验评估模型拟合度 ($\chi^2=186.32$, $p<0.001$)。

影响因素	回归系数	标准误	z 值	p 值
职业规划完整性（详细 vs 无规划）	0.82	0.11	7.45	<0.001
信息获取效率（标准化）	0.45	0.09	5.00	<0.001
实践能力水平（标准化）	0.31	0.10	3.10	<0.01
专业类型（理工类 vs 文科类）	0.28	0.12	2.33	<0.05

结果显示：职业规划完整性对岗位匹配度影响最大（ $\beta=0.82, p<0.001$ ），有详细职业规划的毕业生完全匹配概率显著更高；信息获取效率与岗位匹配度呈正相关（ $\beta=0.45, p<0.001$ ）。

（四）聚类分析

基于核心影响因素（信息获取效率、实践能力水平、职业规划完整性），使用 stats 包的 `kmeans()` 函数对毕业生进行聚类分析，通过肘部法则确定最优聚类数（ $k=3$ ）。

（图表 5：肘部法则图）

R 代码生成

```
# 确保已完成聚类分析所需变量的准备（若未准备，先运行此句）
cluster_vars <- data[, c("信息获取效率_std", "实践能力水平_std", "职业规划完整性_num")]

# 计算不同聚类数 k 的组内平方和
wss <- sapply(1:10, function(k) kmeans(cluster_vars, k, nstart=25)$tot.withinss)

# 生成肘部法则图
png("肘部法则图.png", width=800, height=600, res=100)
plot(1:10, wss, type="b", # 类型为“点+线”
     xlab="聚类数 k",
     ylab="组内平方和",
     main="肘部法则确定最优 k 值",
     pch=16, col="darkred", # 点的样式和颜色
     lwd=2, col.lab="darkblue", # 线宽和坐标轴标签颜色
     cex.main=1.2, cex.lab=1.1, cex.axis=1)

# 标注肘部位置（k=3）
points(3, wss[3], col="darkgreen", pch=17, cex=2) # 绿色三角形标注 k=3
text(3.2, wss[3]+5, "最优 k=3", col="darkgreen", cex=1.1)
dev.off()
```


注：横坐标为聚类数 k（1-10），纵坐标为组内平方和，通过 plot(1:10, wss, type="b")生成，曲线在 k=3 处出现明显拐点。

（图表 6：聚类结果 PCA 可视化图）

R 代码生成

```
# 确保已完成 K-means 聚类（若未完成，先运行此句）
kmeans_result <- kmeans(cluster_vars, centers=3, nstart=25)
data$cluster <- as.factor(kmeans_result$cluster) # 为数据集添加聚类标签

# PCA 降维（将三维变量降至二维）
pca <- prcomp(cluster_vars, scale=FALSE)

# 生成聚类结果 PCA 可视化图
png("聚类 PCA 可视化.png", width=800, height=600, res=100)
plot(pca$x[,1], pca$x[,2], # PC1 为横轴，PC2 为纵轴
      col=data$cluster, # 按聚类标签着色
      main="聚类结果 PCA 可视化",
      xlab=paste("PC1 (解释方差:", round(pca$sdev[1]^2/sum(pca$sdev^2)*100, 1), "%)", # 标注 PC1 解释的方差比例
      ylab=paste("PC2 (解释方差:", round(pca$sdev[2]^2/sum(pca$sdev^2)*100, 1), "%)", # 标注 PC2 解释的方差比例
      pch=16, cex=1.2) # 点的样式和大小
# 添加图例
legend("topright", legend=paste("集群", 1:3), col=1:3, pch=16, cex=1.1)
# 添加网格线，增强可读性
grid(col="gray80", lty=2)
dev.off()
```

注：通过 prcomp()降维后绘制散点图，横坐标为 PC1，纵坐标为 PC2，不同颜色代表 3 个聚类群体，标题为“聚类结果 PCA 可视化”。

聚类群体	占比	核心特征	就业率	平均起薪（元）
集群 1（优质就业群体）	28%	信息获取效率高、实践能力强、职业规划完整	95.3%	8650
集群 2（中等就业群体）	52%	各项指标中等	81.7%	6520
集群 3（就业困难群体）	20%	信息获取效率低、实践能力弱、无明确职业规划	58.2%	4830

补充：聚类群体特征交叉分析

聚类群体	文科类占比	民办院校占比	非中心城市占比
集群 1（优质就业群体）	22.5%	15.7%	31.4%
集群 2（中等就业群体）	45.1%	38.3%	52.6%
集群 3（就业困难群体）	65.3%	62.8%	78.9%

四、结果应用

（一）针对高校的就业服务优化方案

- 差异化培养：**针对聚类结果中的“就业困难群体”，开设实践能力强化训练营与职业规划工作坊，重点提升信息获取能力与实践技能；为文科专业增设跨学科实践课程，缩小与理工类专业的就业差距。
- 资源均衡配置：**建立区域性高校就业联盟，共享企业资源与招聘信息，重点支持非中心城市高校与民办院校，通过线上招聘平台降低信息获取成本。
- 精准就业指导：**基于回归分析结果，将实践能力培养纳入人才培养方案，要求学生毕业前完成不少于 3 个月的专业实习，并建立实习质量考核机制。

（二）针对企业的招聘与合作策略

- 科学招聘：**优化招聘标准，降低院校背景权重，重点考察实践能力与职业规划完整性，通过结构化面试量化评估候选人的岗位匹配度，提高招聘效率。
- 深化校企合作：**扩大“订单班”与现代学徒制项目覆盖范围，不仅与头部高校合作，也与普通高校、民办院校建立合作关系，定向培养符合企业需求的应用型人才。

（三）针对毕业生的个人能力提升建议

- 主动提升实践能力：**尽早参与专业实习、科研项目或创新创业活动，累计实践经历，弥补院校背景或专业类型的劣势。
- 完善职业规划：**大一阶段启动自我探索与职业测评，大二确定职业方向，大三针对性提升岗位所需技能，避免求职盲目性。
- 拓宽信息渠道：**关注企业官网、行业招聘平台、校友内推等多元渠道，提高信息获取效率，把握应届生身份的就业机会。

五、结论

本文通过构建大学生就业影响因素数据集，运用 R 语言完成数据预处理、描述性统计、相关性分析、回归分析及聚类分析，系统量化了各因素对就业质量的影响效应，得出以下核心结论：

1. 实践能力水平、职业规划完整性、院校资源供给、专业类型是影响大学生就业质量的关键因素，其中实践能力的影响最为显著；
2. 就业市场存在一定的资源分配不均，非中心城市高校、民办院校及文科专业毕业生面临更大就业压力，但通过提升实践能力与信息获取效率可有效缓解；
3. 毕业生可分为优质就业、中等就业、就业困难三类群体，不同群体的核心短板不同，需采取差异化的提升策略。

本研究的创新点在于将统计学方法与就业问题深度结合，通过“问题-数据-分析-应用”的完整流程，为就业困境破解提供了量化支撑与可落地的解决方案。后续研究可扩大样本规模，纳入更多影响因素（如数字技能水平、社会资本），并进行纵向追踪分析，进一步优化就业促进策略。

六、附录（R 代码）

```
# 大学生就业问题统计分析完整 R 代码
# 加载所需包
library(mice)
library(psych)
library(ggplot2)
library(reshape2)
library(car)
library(MASS)
library(stats)
library(pROC) # 新增：用于 Logistic 回归 ROC 分析
library(cluster) # 新增：用于聚类轮廓系数检验

# 1. 数据导入与预处理
# 数据导入
data <- read.csv("大学生就业数据.csv", stringsAsFactors = TRUE)
# 查看数据结构
str(data)
# 查看缺失值情况
sum(is.na(data))

# 缺失值处理
# 连续变量中位数填充
data$起薪水平[is.na(data$起薪水平)] <- median(data$起薪水平, na.rm = TRUE)
data$实践能力水平[is.na(data$实践能力水平)] <- median(data$实践能力水平, na.rm = TRUE)
# 分类变量众数填充
get_mode <- function(x) {
  names(sort(-table(x)))[1]}
}
```

```

data$职业规划完整性[is.na(data$职业规划完整性)] <- get_mode(data$职业规划完整性)
# 多重插补验证
imp <- mice(data, m=5, method='pmm', seed=123)
data_imp <- complete(imp)

# 异常值处理（仅标记，不删除）
iqr_salary <- IQR(data$起薪水平)
lower_salary <- quantile(data$起薪水平, 0.25) - 1.5*iqr_salary
upper_salary <- quantile(data$起薪水平, 0.75) + 1.5*iqr_salary
data$salary_outlier <- ifelse(data$起薪水平 < lower_salary | data$起薪水平 > upper_salary, 1, 0)

# 变量标准化与转换
data$信息获取效率_std <- scale(data$信息获取效率)
data$实践能力水平_std <- scale(data$实践能力水平)
data$职业规划完整性_num <- as.numeric(data$职业规划完整性)
data$岗位匹配度_num <- as.numeric(data$岗位匹配度)

# 数据子集划分
data_public <- subset(data, 院校资源供给 %in% c(1,2))
data_private <- subset(data, 院校资源供给 == 3)
data_science <- subset(data, 专业类型 == 1)
data_liberal <- subset(data, 专业类型 == 2)

# 2. 描述性统计分析
# 连续变量描述性统计
describe(data[, c("起薪水平", "信息获取效率", "实践能力水平")])
# 分类变量频数统计
prop.table(table(data$就业率))
prop.table(table(data$专业类型, data$就业率), margin=1)

# 可视化
# 起薪水平直方图（保存为图片）
png("起薪水平直方图.png", width=800, height=600)
hist(data$起薪水平, main="毕业生起薪水平分布", xlab="月收入（元）", col="lightblue")
dev.off()
# 不同专业类型就业率条形图（保存为图片）
png("专业就业率条形图.png", width=800, height=600)
barplot(prop.table(table(data$专业类型, data$就业率), margin=1),
        main="不同专业类型就业率对比",
        xlab="专业类型（1=理工类, 2=文科类, 3=艺术类, 4=交叉学科）",
        ylab="就业率",
        legend.text = c("未就业", "就业"))
dev.off()

```

```

# 3. 相关性分析
cor_vars <- c("起薪水平", "信息获取效率_std", "实践能力水平_std", "职业规划完整性_num")
cor_matrix <- cor(data[, cor_vars], method = "pearson")
print(cor_matrix)
# 相关性热力图（保存为图片）
png("相关性热力图.png", width=800, height=600)
melt_cor <- melt(cor_matrix)
ggplot(melt_cor, aes(x=Var1, y=Var2, fill=value)) +
  geom_tile() +
  scale_fill_gradient2(low="blue", high="red", mid="white", midpoint=0) +
  labs(title="变量相关性热力图", x="", y="") +
  theme_minimal()
dev.off()

# 多重共线性检验
model_temp <- lm(起薪水平 ~ 信息获取效率_std + 实践能力水平_std + 职业规划完整性_num, data=data)
vif(model_temp)

# 4. 回归分析
# 4.1 二元 Logistic 回归（因变量：就业率）
logit_model <- glm(就业率 ~ 信息获取效率_std + 实践能力水平_std + 职业规划完整性_num + 院校资源供给 + 专业类型 + 性别 + 地域,
                  data=data, family=binomial(link="logit"))
logit_model_opt <- step(logit_model, direction="both", trace=FALSE)
summary(logit_model_opt)
exp(coef(logit_model_opt)) # OR 值
# 新增：ROC 曲线分析（保存为图片）
png("Logistic 回归 ROC 图.png", width=800, height=600)
roc_curve <- roc(data$就业率, predict(logit_model_opt, type="response"))
plot(roc_curve, main="Logistic 回归 ROC 曲线", auc.polygon=TRUE, auc.polygon.col="lightblue")
text(0.5, 0.5, paste("AUC =", round(auc(roc_curve), 3)))
dev.off()

# 4.2 多元线性回归（因变量：起薪水平）
lm_model <- lm(起薪水平 ~ 信息获取效率_std + 实践能力水平_std + 职业规划完整性_num + 院校资源供给 + 专业类型 + 地域,
              data=data)
# 模型诊断图（保存为图片）
png("线性回归诊断图.png", width=800, height=800)
par(mfrow=c(2,2))
plot(lm_model)
dev.off()
summary(lm_model)
# 新增：预测效果验证
data$pred_salary <- predict(lm_model)

```

```

cor(data$起薪水平, data$pred_salary) # 预测值与实际值相关性

# 4.3 有序 Logistic 回归（因变量：岗位匹配度）
ord_logit_model <- polr(岗位匹配度 ~ 信息获取效率_std + 实践能力水平_std + 职业规划完整性_num + 专
专业类型,

                        data=data, method="logistic")
summary(ord_logit_model)
anova(ord_logit_model, update(ord_logit_model, . ~ 1)) # 似然比检验

# 5. 聚类分析
cluster_vars <- data[, c("信息获取效率_std", "实践能力水平_std", "职业规划完整性_num")]
# 肘部法则确定 k 值（保存为图片）
png("肘部法则图.png", width=800, height=600)
wss <- sapply(1:10, function(k) kmeans(cluster_vars, k, nstart=25)$tot.withinss)
plot(1:10, wss, type="b", xlab="聚类数 k", ylab="组内平方和", main="肘部法则确定最优 k 值")
dev.off()
# K-means 聚类（k=3）
kmeans_result <- kmeans(cluster_vars, centers=3, nstart=25)
data$cluster <- as.factor(kmeans_result$cluster)
# 聚类结果描述
aggregate(cluster_vars, by=list(data$cluster), mean)
# 新增：轮廓系数检验（评估聚类效果）
sil <- silhouette(as.integer(data$cluster), dist(cluster_vars))
png("聚类轮廓系数图.png", width=800, height=600)
plot(sil, main="聚类轮廓系数图", col=1:3)
dev.off()
# PCA 降维可视化（保存为图片）
png("聚类 PCA 可视化.png", width=800, height=600)
pca <- prcomp(cluster_vars, scale=FALSE)
plot(pca$x[,1], pca$x[,2], col=data$cluster, main="聚类结果 PCA 可视化", xlab="PC1", ylab="PC2", pch=16)
legend("topright", legend=paste("集群", 1:3), col=1:3, pch=16)
dev.off()
# 聚类群体特征交叉分析
table(data$cluster, data$专业类型)
prop.table(table(data$cluster, data$专业类型), margin=1)
table(data$cluster, data$院校资源供给)
prop.table(table(data$cluster, data$院校资源供给), margin=1)

```